

## La regressione logistica multinomiale

# Introduzione

Il modello di regressione logistica può essere generalizzato per considerare il caso nel quale la variabile dipendente  $Y$  é policotomica e assume  $m+1$  modalità.

- $0, 1, \dots, m$ : modalità di  $Y$ ;
- 0 categoria di riferimento;
- $x = (x_1, x_2, \dots, x_p)$ : vettore delle variabili esplicative;

Per ogni modalità di  $Y$  si definisce la funzione logit:

$$g_1(x) = \text{logit}_1(x) = \ln \left[ \frac{P(Y = 1|x)}{P(Y = 0|x)} \right] = \beta_{10} + \beta_{11}x_1 + \dots + \beta_{1p}x_p$$

$$g_2(x) = \text{logit}_2(x) = \ln \left[ \frac{P(Y = 2|x)}{P(Y = 0|x)} \right] = \beta_{20} + \beta_{21}x_1 + \dots + \beta_{2p}x_p$$

$$g_3(x) = \text{logit}_3(x) = \ln \left[ \frac{P(Y = 3|x)}{P(Y = 0|x)} \right] = \beta_{30} + \beta_{31}x_1 + \dots + \beta_{3p}x_p$$

$$g_m(x) = \text{logit}_m(x) = \ln \left[ \frac{P(Y = m|x)}{P(Y = 0|x)} \right] = \beta_{m0} + \beta_{m1}x_1 + \dots + \beta_{mp}x_p$$

Tutte le modalità sono confrontate con quella di riferimento. L'i-esimo logit esprime la propensione della variabile dipendente ad assumere l'i-esima modalità rispetto alla modalità di riferimento 0 in corrispondenza del valore  $x$  del vettore delle variabili esplicative.

$$g_3(x) = \text{logit}_3(x) = \ln \left[ \frac{P(Y = 3|x)}{P(Y = 0|x)} \right] = \beta_{30} + \beta_{31}x_1 + \dots + \beta_{3p}x_p$$

$$g_m(x) = \text{logit}_m(x) = \ln \left[ \frac{P(Y = m|x)}{P(Y = 0|x)} \right] = \beta_{m0} + \beta_{m1}x_1 + \dots + \beta_{mp}x_p$$

Tutte le modalità sono confrontate con quella di riferimento. L'i-esimo logit esprime la propensione della variabile dipendente ad assumere l'i-esima modalità rispetto alla modalità di riferimento 0 in corrispondenza del valore  $x$  del vettore delle variabili esplicative.

Le probabilità con le quali la variabile dipendente assume le diverse modalità, condizionate ad  $x$ , risultano:

$$\pi_0(x) = P(Y = 0|x) = \frac{1}{1 + \exp[g_1(x)] + \dots + \exp[g_m(x)]}$$

$$\pi_1(x) = P(Y = 1|x) = \frac{\exp[g_1(x)]}{1 + \exp[g_1(x)] + \dots + \exp[g_m(x)]}$$

$$\pi_m(x) = P(Y = m|x) = \frac{\exp[g_m(x)]}{1 + \exp[g_1(x)] + \dots + \exp[g_m(x)]}$$

Per stimare il modello la variabile dipendente é codificata mediante  $m + 1$  variabili dicotomiche  $y_j$  tali che  $y_j = 1$  quando  $Y$  assume la  $j$ -esima modalit  e 0 altrimenti.

La funzione di verosimiglianza   data da

$$L(\beta) = \prod_{i=1}^n [\pi_0(x_i)^{y_{0i}} \pi_1(x_i)^{y_{1i}} \dots \pi_m(x_i)^{y_{mi}}]$$

e viene massimizzata numericamente.

# Regressione logistica ordinale

Quando la variabile dipendente assume modalità ordinate é opportuno utilizzare il modello della regressione logistica ordinale.

Si possono distinguere tre possibili modelli:

- Proportional-odds model
- Continuation-ratio model
- Adjacent-category model

# Proportional-odds model

Nel proportional-odds model per ogni modalità  $j$  della variabile dipendente  $Y$  si considera il logit fra le categorie successive a  $j$  rispetto alle precedenti:

$$c_j(x) = \ln \left[ \frac{P(Y > j|x)}{P(Y \leq j|x)} \right]$$

Esiste inoltre una variabile latente  $Y^*$  che dipende dai regressori. L'insieme dei valori di  $Y^*$  é suddiviso in  $m + 1$  sottoinsiemi sulla base di quelli che sono dei valori soglia  $((-\infty, \tau_1), (\tau_1, \tau_2), \dots, (\tau_m, +\infty))$

Il logit risulterà essere allora:

$$c_j(x) = \ln \left[ \frac{P(Y > j|x)}{P(Y \leq j|x)} \right]$$



# Proportional-odds model

Nel proportional-odds model per ogni modalità  $j$  della variabile dipendente  $Y$  si considera il logit fra le categorie successive a  $j$  rispetto alle precedenti:

$$c_j(x) = \ln \left[ \frac{P(Y > j|x)}{P(Y \leq j|x)} \right]$$

Esiste inoltre una variabile latente  $Y^*$  che dipende dai regressori. L'insieme dei valori di  $Y^*$  é suddiviso in  $m + 1$  sottoinsiemi sulla base di quelli che sono dei valori soglia  $((-\infty, \tau_1), (\tau_1, \tau_2), \dots, (\tau_m, +\infty))$

Il logit risulterà essere allora:

$$c_j(x) = \ln \left[ \frac{P(Y > j|x)}{P(Y \leq j|x)} \right]$$

# Continuation-ratio model

Nel continuation-ratio model si considera il logit fra ciascuna categoria della variabile dipendente e le precedenti. Dato il valore delle variabili esplicative si ha:

$$r_j(x) = \ln \left[ \frac{P(Y = j|x)}{P(Y < j|x)} \right] = \beta_{j0} + \beta_{j1}x_1 + \dots + \beta_{jp}x_p$$

Al variare della modalità della variabile dipendente variano i parametri del logit, quindi il numero di parametri da stimare sarà  $p \times m$  e coincide con quello del modello multinomiale.

Questo modello é stimato mediante  $m$  regressioni logistiche binarie nelle quali si confronta la  $j$ -esima categoria della variabile dipendente rispetto alle precedenti. Il valore della log-verosimiglianza é dato dalla somma dei valori ottenuti nelle singole regressioni.

# Adjacent-category model

Questo modello é utile nel confronto fra successive modalitá della variabile dipendente. Il logit fra categorie adiacenti é dato da

$$a_j(x) = \ln \left[ \frac{P(Y = j|x)}{P(Y = j-1|x)} \right] = \beta_0 + x_1\beta_1 + \dots + x_p\beta_p$$

Il logit rispetto alla categoria di riferimento é dato da

$$\ln \left[ \frac{P(Y = j|x)}{P(Y = 0|x)} \right] =$$

$$\ln \left[ \frac{P(Y = j|x)}{P(Y = 0|x)} \right] + \ln \left[ \frac{P(Y = 2|x)}{P(Y = 1|x)} \right] + \dots + \ln \left[ \frac{P(Y = j|x)}{P(Y = j-1|x)} \right]$$

# Adjacent-category model

Questo modello é utile nel confronto fra successive modalitá della variabile dipendente. Il logit fra categorie adiacenti é dato da

$$a_j(x) = \ln \left[ \frac{P(Y = j|x)}{P(Y = j-1|x)} \right] = \beta_0 + x_1\beta_1 + \dots + x_p\beta_p$$

Il logit rispetto alla categoria di riferimento é dato da

$$\ln \left[ \frac{P(Y = j|x)}{P(Y = 0|x)} \right] =$$

$$\ln \left[ \frac{P(Y = j|x)}{P(Y = 0|x)} \right] + \ln \left[ \frac{P(Y = 2|x)}{P(Y = 1|x)} \right] + \dots + \ln \left[ \frac{P(Y = j|x)}{P(Y = j-1|x)} \right]$$